

Prithvi-EO-2.0 在海光 K100 AI 加速卡上的可 审计混合精度部署：精度、内核路径与系统 权衡

匿名作者

匿名机构

匿名地点

anonymous@example.com

摘要—地理空间基础模型的部署需要超越名义数据类型和文件压缩率的证据。本文给出一个面向特定硬件与运行时的可审计案例：将由 Prithvi-EO-2.0-300M 与 UPerNet 组成的约 3.19 亿参数洪水水体分割模型部署到海光 K100 AI 加速卡。验证链覆盖固定 90 幅影像上的任务效用、ONNX Runtime 执行提供者放置、实际 GEMM 内核路径、同拓扑与 same-CLI 性能，以及不可变部署包的运行行为。实验建立 25 段 FP32 分母，并评估 6 个固定的诊断知情 FP16/INT8 配置 M0–M5。M4 取得混合精度中的最高实测 mIoU (0.86037)；M5 取得 0.86027 mIoU 和 22.080 ms 端到端 logits 中位时延，相比 25 段 FP32 的 22.209 ms 低约 0.58%，本文将其表述为时延持平，而非正式 INT8 加速。profile 中 MIGraphX 事件为正且 CPU 提供者事件为 0，trace 进一步识别出 INT8 block 中的 I8II GEMM 和 FP16 block 中的 HBH GEMM。然而，在生产式 same-CLI 比较中，M5 比单体 Full FP16 慢 73.642%，尽管完整部署载荷减少 23.463%。两个部署包均通过 5 次冷启动、3 次主动终止恢复、双节点冒烟测试和 60 分钟稳定性测试，未出现推理错误、非有限输出或预测漂移。对于本文评估的 checkpoint 与 K100 软件栈，Full FP16 是速度优先的主部署方案，M5 是存储优先的可部署备选。

Index Terms—地理空间基础模型，混合精度，部署验证，MIGraphX，海光 K100

I. 引言

地理空间基础模型 (GeoFM) 通过大规模预训练迁移到土地覆盖制图、变化检测和灾害响应等下游对地观测任务。Prithvi-EO-2.0 在全球 Harmonized Landsat 与 Sentinel-2 时序数据上引入多时相和位置感知预训练 [1]；相关掩码自编码工作也证明了卫星影像光谱结

构与时间结构的价值 [2]。但是，这类模型通常具有数亿参数，实际部署图还包含 Transformer 编码器、归一化、多尺度特征重建和密集预测任务头。

低精度推理可以降低 artifact 容量，并可能暴露低精度内核，但任务保持、加速卡放置、实际算术路径和应用时延是不同主张。针对视觉 Transformer 的后训练量化研究处理激活分布、LayerNorm 通道差异与尺度重参数化 [3]–[5]；硬件感知混合精度研究则强调转换开销和运行时约束 [6]。因此，编译器融合、图划分、Q/DQ 边界、布局转换和会话调度都可能抵消名义算术收益。

本文研究 Prithvi-EO-2.0-300M 与 UPerNet [7] 在海光 K100 AI 加速卡上的部署。本文不提出新的量化算法，也不提出可跨平台迁移的通用混合精度策略。本文是一项面向特定硬件与运行时的部署案例研究。历史上失败的 CPU/MIGraphX 严格 logits 诊断被永久保留，同时另设应用级轨道评估不可变 artifact 在目标软件栈上的可用性。证据被组织为任务效用、提供者放置、实际内核、系统性能和运行可靠性五层。

本文的主要贡献如下：

- 1) 提出一套五层可审计证据框架，将任务效用、提供者放置、实际内核、性能和运行可靠性分开，避免把名义 INT8 或压缩率直接当作部署成功。
- 2) 建立设备驻留 OrtValue 传递的同拓扑 25 段 FP32 分母，使 FP32 与 M0–M5 的分段系统时延比较具有一致拓扑。
- 3) 将不可变 ONNX 配置、提供者 profile 与逐 block

I8II/HBH trace 关联起来:33 个去重 artifact trace 支撑 144 个“候选-block”映射, profile 中未观察到 CPU 提供者事件。

- 4) 将 M5 和 Full FP16 封装为不可变部署包, 并验证冷启动、主动恢复、跨节点执行、60 分钟运行和生产式 same-CLI 比较。

本文不声称混合图中的所有算子均为原生 INT8, 不声称 CPU 与 MIGraphX logits 严格等价, 也不把 INT8 算术路径直接表述为整模型加速。

II. 相关工作

A. 地理空间基础模型与下游适配

视觉 Transformer (ViT) 将图像切分为 patch 序列并使用自注意力进行表征学习 [8]。遥感掩码预训练随后引入多时相、多光谱、显式空间尺度及对齐的雷达-光学数据, SatMAE、Scale-MAE 和 CROMA 是其中的代表 [2], [9], [10]。RingMo 与持续地理空间预训练扩展了跨传感器和下游任务的表征 [11], [12]; SkySense 与 DOFA 则研究多模态或传感器灵活的对地观测编码器 [13], [14]。Prithvi-EO-2.0 进一步采用多时相与位置感知预训练并支持下游适配 [1]。本文不提出新骨干, 而是研究一个已微调 300M 模型在目标加速卡上的精度变换与部署行为。

B. Transformer 的后训练量化与混合精度

当量化语义与硬件内核匹配时, 整数推理能够缩小模型并执行整数算术 [15]。视觉 Transformer PTQ 研究排序保持校准、非高斯激活、LayerNorm 通道差异和尺度重参数化 [3]–[5], [16]; 硬件感知和敏感性知情的混合精度工作则依据设备反馈或层级信号分配位宽 [6], [17], [18]。本文既不提出 PTQ 方法, 也不估计任务损失敏感性, 而是依据同一冻结 artifact 在两个后端上的差异构建固定精度配置。

C. 硬件感知部署与运行时编译

ONNX Runtime 通过执行提供者抽象支持跨平台部署 [19]。MIGraphX 对计算图进行编译和算子下沉, 并通过融合等变换影响实际执行 [20]。可复现推理基准还需要明确场景、精度约束和计时定义, 而不能依赖单个无上下文的时间值 [21]。但是, 提供者被注册或排在首位, 不等于算子确实落卡; 算子落卡也不等于实际采用了整数内核。本文因此联合使用提供者 profile、

kernel trace 和端到端测量, 而不是用图中数据类型或文件大小代替加速证据。

D. 遥感模型的部署验证

遥感压缩研究开始联合考虑模型大小、分辨率与任务精度 [22]。面向真实系统的 GeoFM 工作进一步强调应用需求、领域适配和基准之外的经验验证 [23]; PhiSat-1 展示了受限对地观测场景中的星上深度学习验证 [24], 近期综述则从模型优化、软件工具链和受限硬件三个方面组织星载遥感基础模型部署 [25]。这些工作共同说明, 部署 artifact 必须可执行、可测量并可恢复, 而不能只在离线框架中保持精度。

在本文审阅的研究范围内, 尚未识别出一条同时报告任务效用、提供者放置、实际内核、同拓扑性能和目标 GeoFM 软件栈运行行为的完整评估链。本文联合报告这些证据层, 同时把结论限制在所评估的 checkpoint 与 K100 软件栈。

III. 模型与部署方法

部署过程从冻结 FP32 参考模型出发, 经后端差异诊断和固定精度配置后进入 K100 执行。证据链将任务效用、提供者放置、实际内核、系统性能和运行验收明确分开。

图 1 概括不可变 artifact 流水线和用于形成部署决策的五层证据。该图描述的是审计结构而非新的量化算法: 文件精度、提供者放置、实际内核精度、系统性能和运行可靠性仍是相互独立的主张。

A. 任务与冻结输入契约

实验任务为 Sen1Floods11 [26] 二分类洪水水体分割。模型由 Prithvi-EO-2.0-300M 编码器和 UPerNet 解码器组成, 总参数约 3.19 亿。评估固定使用公开测试集的 90 幅影像和 3,927,398 个有效像素。输入形状为 $1 \times 6 \times 224 \times 224$, 六个波段依次为 BLUE、GREEN、RED、NIR_NARROW、SWIR_1 和 SWIR_2。输入为经过数据集 10^{-4} 比例缩放后的有限 FP32 反射率张量; 归一化已嵌入导出模型, 部署客户端不得重复执行。

任务指标由全局混淆矩阵计算, 包括 mIoU、Water IoU、pixel accuracy 和 Boundary Water IoU。对于二值水体掩膜 m , 实现采用半径为 2 像素的形态学梯度:

$$B(m) = \delta_2(m) - [1 - \delta_2(1 - m)],$$

$$\text{BIoU} = \frac{|B(\hat{m}) \cap B(m) \cap V|}{|(B(\hat{m}) \cup B(m)) \cap V|}, \quad (1)$$

部署流水线



五层独立证据



边界：严格CPU-MIGraphX logits等价仍为 failed

图 1. K100 可审计部署总览。冻结模型与输入身份依次进入后端诊断、固定 M0-M5 精度映射和 25 个常驻 ONNX/MXR 会话；不可变 artifact 与五类证据保持分离，最终工程决策不能由名义数据类型直接推出。

其中， δ_2 是步长为 1、核为 5×5 方形的 max pooling，水体编码为类别 1， V 为 target 不等于 ignore 值的有效像素掩膜。交集与并集在 90 幅影像上全局累计；若全局并集为空，则报告未定义而不是人为赋值。早期 artifact 中的“corrected”表示修复了 ignore mask 广播：掩膜在应用前显式加入单例通道维，避免从 $N \times H \times W$ 错误广播为 $N \times N \times H \times W$ 。因此正文和表格统一称为 Boundary Water IoU。相对冻结 FP32 的应用级准入标准为：mIoU 下降不超过 0.5 个百分点 (pp)，Water IoU 和 Boundary Water IoU 下降均不超过 1.0 pp，有效像素预测一致率不低于 99.5%，且非有限输出为 0。

B. 25 段执行拓扑

部署骨干由 24 个 Transformer block 段和 1 个 UPerNet head 段组成。所有段间接口统一为 FP32，并通过设备驻留的 ONNX Runtime OrtValue 传递，避免相邻段之间回到主机内存。为适配目标编译器，必要的 LayerNorm 被展开，解码器 ConvTranspose 被重写，并在 head 中加入 fpn4 MaxPool barrier 以获得稳定的加速卡放置。每个 ONNX 段及其 MXR 编译缓存均具有冻结的独立身份。

FP32 和混合精度候选采用相同的 25 段拓扑。单体 FP32 会话与 25 会话混合流水线具有不同的调度、缓存和段边界成本，因此本文只使用 25 段 FP32 作为同协议性能分母。

C. 后端差异定位

配置序列并非只依据最终 logits，而是通过显式逐段后端诊断获得。对于第 i 段，令 x_i^C 表示 CPU 参考链生成的输入， x_i^M 表示 MIGraphX 累计链生成的输入， f_i^C 与 f_i^M 分别表示同一冻结段 artifact 在 CPU 和 MIGraphX 上的执行。定义三个互补差异：

$$\begin{aligned} L_i &= \text{MAE}(f_i^C(x_i^C), f_i^M(x_i^C)), \\ C_i &= \text{MAE}(f_i^C(x_i^C), f_i^M(x_i^M)), \\ P_i &= \text{MAE}(f_i^M(x_i^C), f_i^M(x_i^M)). \end{aligned} \quad (2)$$

其中， L_i 为相同输入条件下的局部 CPU-MIGraphX 差异， C_i 为经过第 i 段后的整链累计差异， P_i 表示上游漂移对同一个 MIGraphX 段输出的影响。除 MAE 外，还记录最大绝对差异和相对 ℓ_2 差异。 L_i 、 C_i 和 P_i 均为后端差异诊断量：它们既不是纯 FP32 到 INT8 量化误差，也不是任务损失敏感性。

诊断使用公开测试集中的一幅冻结真实影像，并只为暴露段边界而在主机侧暂存中间张量。它不是性能实验，也没有改变正式部署的设备驻留协议。25 个段仍全部要求 MIGraphX 事件大于 0、CPU 提供者事件为 0。由于一幅公开测试影像参与了后端差异诊断和后续配置序列构建，90 幅影像结果应被理解为固定部署验证案例，而不是对配置泛化能力的无偏留出估计。本

表 I
混合精度候选定义

候选	FP16 骨干 block	INT8 block	Head
M0	无	0-23	FP32
M1	0	其余 23 层	FP32
M2	0、14	其余 22 层	FP32
M3	0、14、17	其余 21 层	FP32
M4	0、14、17、18	其余 20 层	FP32
M5	0、14-21	其余 15 层	FP32

文不声称所观察的 block 模式能够跨影像、checkpoint、任务或加速卡软件栈泛化。

segment 0 需要单独解释。它直接接收六波段图像，在第一个 Transformer block 之前还包含从图像到 token 的前端，包括归一化和 patch embedding。内部 checkpoint 将第一次明显分歧定位在 patch-embedding 卷积的反量化输出，MAE 为 0.1316；attention-score 处 MAE 达到 0.3404；第二个 MLP 投影处达到 0.3792；最终 segment 输出为 0.4239。只将 patch embedding 恢复为 FP32 虽然能降低误差，却不能消除差异，因此 block 0 的大误差不是由某一个卷积单独造成的。基于这一证据，候选设计保护整个第一段，而不是只保护单个算子。

D. 诊断知情的精度配置

表 I 给出固定且可审计的配置序列，而不是自动搜索算法。M0 将 24 个骨干 block 全部设为 INT8，head 保持 FP32。M1 将诊断影像中高差异的 block 0 保护为 FP16；M2-M4 依次加入 block 14、17 和 18；M5 将 block 14-21 整体设为 FP16。FP16 段使用 FP16 权重和激活，但保留 FP32 LayerNorm 统计岛，且所有 Cast 均封装在段内；INT8 段保持冻结 QDQ 语义；head 始终为 FP32。

图 2 把实测后端差异分布与固定配置对应起来。M1-M4 依次保护诊断影像中的离散峰值，而 M5 保护连续的后期高差异区域；FP32 head 始终固定，以隔离骨干精度映射的影响。

E. 量化与模型转换细节

源模型为使用 TerraTorch 1.2.8 训练的冻结 Prithvi-EO-2.0-300M-UPerNet checkpoint (SHA-256 前缀为 59f031)。其 FP32 ONNX 以 opset 17 导出，输入 image 和输出 logits 分别为 FP32 [1, 6, 224, 224]

与 [1, 2, 224, 224]，输入归一化已嵌入图中；导出一致性检查的最大绝对差异为 4.768×10^{-6} 。冻结 sidecar 未保留精确 PyTorch exporter 版本，本文不作推断。

INT8 段复用由 ONNX Runtime quantization 1.26.0 生成的不可变 static-PTQ QDQ artifact；K100 实验没有重新估计 scale 或 zero point。激活和权重均使用 signed INT8 Q/DQ 张量 (S8S8)；激活非对称、权重对称，权重采用 per-channel、激活采用 per-tensor。量化器实际选择的通道 axis 及解析后的 scale/zero-point 张量 dtype 没有在 sidecar 中单独保留，因此本文不重构这些字段。MinMax 校准按数据集顺序使用官方训练集前 64 幅影像，执行确定性 resize 和 10^{-4} 输入缩放，不使用随机增强和标签。白名单为 Conv、MatMul 和 Gemm；骨干 artifact 实际选中 1 个 Conv 与 144 个 MatMul。LayerNorm、Softmax、残差 Add、Resize 及其他未选中算子保持浮点路径。Q/DQ 对置于每段内部已选算子边界，UPerNet head 和所有段外部接口均保持 FP32。

冻结的 Full FP16 源 artifact 由 onnxconverter-common 1.16.0 转换，保留 FP32 外部 I/O，包含 332 个 FLOAT16 initializer，并在转换记录中修补 48 个 attention Cast。抽取后的 FP16 段使用 FP16 权重与激活，但通过显式 FP32 岛计算 LayerNorm 统计量，Cast 全部封装在段内。ONNX Runtime 1.19.2 通过 MIGraphX 5.1.0 Execution Provider 将每个不可变 ONNX 段编译或加载为 MXR 缓存；下文以模型和缓存的 size/SHA 身份界定实际编译产物，而不猜测未记录的命令行。

F. 分层证据协议

实验区分五条证据轨道。

任务轨道：每个候选均在 90 个固定样本上使用 3 个新进程独立评估，由上述任务指标决定应用准入。

性能轨道：只有任务准入通过后，才使用 batch 1、30 次预热、3 个新进程、每进程 100 次正式测量。报告 median、P95、P99、吞吐量和轮间 median CV；CV 超过 5% 时禁止正式速度表述。

放置轨道：每个段的 profile 必须满足 MIGraphX 事件大于 0、CPU 提供者事件等于 0，且段间值保持在设备 OrtValue 中。




图 2. 单幅诊断影像的 CPU-MIGraphX 后端差异 profile 及固定 M0-M5 精度映射。圆圈标记 M1-M4 使用的选定峰值，M5 保护 block 14-21；该 profile 具有案例特异性，不估计任务损失效应。

内核轨道：利用 hipprof 识别每个去重 block artifact 的 GEMM 路径。INT8 block 目标路径为 I8II，FP16 block 目标路径为 HBH；Q/DQ、Cast、布局转换和 Memcpy 分别统计。

运行轨道：部署包通过 manifest SHA-256 锁定，并执行冷启动、主动恢复、跨节点和 60 分钟连续运行测试。

此外，CPU 与 MIGraphX 之间更严格的 logits 比较永久保留为非阻塞诊断。它不能覆盖任务证据，其失败结果将在第 VI 节明确披露。

IV. 实验设置

实验使用两台 K100 节点，核验环境见表 II。正式实验冻结容器镜像、运行时指纹、模型和缓存 SHA、输入 SHA、提供者 profile 以及原始时延数组。放置测试禁用隐式 CPU fallback，并独立解析 profile 证据。

系统性能区分两个口径。Model-only 以已经驻留设备的输入 OrtValue 为起点，并将 logits 留在设备；端到端 logits 使用公共推理 harness 完成外部输入到 logits 的路径。最后的配对比较让 M5 和 Full FP16 通过同一

个公共 CLI 和同一个 K100BundleRunner.run 代码路径执行。

完整部署包接受形状为 $1 \times 6 \times 224 \times 224$ 的有限 FP32 张量，输出形状为 $1 \times 2 \times 224 \times 224$ 的 FP32 logits 和 uint8 类别图。非法 shape、dtype 或 NaN/Inf 直接失败，不进行静默转换。

A. 比较范围

表 III 明确区分全文使用的三种比较范围。所有结论仅在对对应范围内解释，不能跨不同图拓扑或 CLI 路径推导“纯精度加速”。

B. 可复现性与 Artifact 追溯

每项正式结果均关联不可变 ONNX 与 MXR SHA-256、固定输入 hash、容器 digest、运行时指纹和配置 manifest。项目证据包还保留原始时延数组、提供者 profile、kernel trace、完整 bundle manifest、静态校验 receipt 和排除账本；失败启动被单独保存，不会被静默改写为通过。上述材料随项目证据包保留，本文不声称 artifact 已经公开发布。

表 II
硬件、软件与测量环境

类别	已核验配置
加速卡	K100 AI 加速卡；2 个节点；hy-smi 观测设备显存 65,520 MiB。
主机操作系统	Ubuntu 20.04 LTS；Linux 5.4.0-216-generic。
主机内存	可见内存 62 GiB。
容器镜像	Ubuntu 22.04.5；镜像 sha256:bdc7e817...17b01。
语言/框架	Python 3.10.12；PyTorch 2.5.1；HIP 6.3.25405。
编译器/运行时	DTK 25.04.2；MIGraphX 5.1.0+das.opt1.dtk25042；ONNX Runtime 1.19.2+das.opt1.dtk25042。
运行策略	Batch 1；观测为动态/auto 性能模式；预检时无其他 K100 任务。
计时方法	主机 perf_counter_ns；I/O binding 显式同步输入，并在结束时同步最终输出。
重复协议	30 次预热；3 个新进程 $\times$ 100 次正式测量。
Model-only 范围	设备驻留输入 OrtValue 到设备驻留 logits。
端到端 logits 范围	外部 FP32 输入传输、推理到最终 logits 回传主机。
吞吐量定义	Batch 1 下为 $N \times 1000 / \sum_j t_j$ sample/s，其中 t_j 的单位为 ms。
增量显存定义	独立新进程；mem_info_vram_used 峰值减去 20 个空闲基线样本的中位数；目标轮询间隔 10 ms。
运行遥测	稳定性测试每 5 s 采样温度、功耗与显存。
输入契约	FP32 $1 \times 6 \times 224 \times 224$ ；有限值；固定六波段顺序。

表 III
比较范围与允许解释

范围	比较 artifact	受控接口	允许解释
同拓扑	25 段 FP32 与 M0-M5	相同 25 会话、设备驻留 Ort-Value 拓扑	分段系统时延与运行重复性
Same-CLI	最终 M5 部署包与单体 Full FP16	相同 固定输入与 K100BundleRunner.run 路径	生产式部署决策，不能隔离算术精度影响
存储	ONNX+MXR 逻辑容量与完整部署包载荷	分别定义并按字节统计	仅用于容量比较，不推导时延

V. 实验结果

A. 逐层后端差异分布

表 IV 给出完整逐段定位结果，并显示三种关键模式。第一，segment 0 是最早且最大的局部 CPU-MIGraphX 分歧： $L_0 = 0.4239$ ，相对 $\ell_2 = 0.2978$ ；由于两条链从完全相同的图像开始， $P_0 = 0$ 。因此，该段产生的后端差异可能进入后续残差流。第二，block 14-21 形成后期高差异区域，其中 14、17、18 是最明显的局部峰值，而 15、16、19-21 仍处于中等偏高水平。M2-M4 依次加入三个峰值；M5 则保护完整的 14-21 连续区域，用于比较连续区域保护与孤立峰值保护的部署结果。

第三，局部误差和累计误差均不随深度单调变化。block 22 和 23 具有最小的两个局部相对 ℓ_2 误差 (0.0199 和 0.0190)，但累计 MAE 仍超过 0.81，因为它们继承了前面已经形成的漂移。相反，block 7-13 即使引入非

零局部误差，累计误差也会阶段性下降。原因在于误差是带方向的向量而不是只能逐层相加的非负标量；残差相加、归一化、注意力混合和 MLP 投影都可能旋转、衰减或放大已有扰动。

局部最大值也必须与 MAE 和相对 ℓ_2 联合解释。block 4 的最大差异达到 2.6298，但 MAE 只有 0.0581，说明主要是稀疏离群值，而不是广泛失真。block 14 的最大值较小，但 MAE 和相对 ℓ_2 明显更高，因此被纳入 FP16 保护配置。FP32 head 的局部提供者差异也较高，但多尺度特征映射为两个 logits 后，累计输出 MAE 降至 0.1871。Head 通过独立的 fpn4-barrier 兼容性修复处理，不被计作 INT8 骨干 block。

表 IV
冻结真实样本上的逐段 CPU-MIGRAPHX 后端差异定位

段	L_i MAE	局部 max	相对 ℓ_2	C_i MAE	精度作用	段	L_i MAE	局部 max	相对 ℓ_2	C_i MAE	精度作用
0	0.4239	3.5917	0.2978	0.4239	M1-M5 FP16	13	0.0797	0.4972	0.0507	0.6658	INT8
1	0.0642	1.4324	0.0459	0.4944	INT8	14	0.1284	0.7954	0.0815	0.6615	M2-M5 FP16
2	0.0749	0.9584	0.0478	0.5913	INT8	15	0.1076	0.5345	0.0663	0.6586	M5 FP16
3	0.0709	1.1014	0.0440	0.6450	INT8	16	0.0958	0.9325	0.0587	0.6658	M5 FP16
4	0.0581	2.6298	0.0396	0.6628	INT8	17	0.1327	1.2882	0.0807	0.6749	M3-M5 FP16
5	0.0656	0.7842	0.0409	0.6985	INT8	18	0.1258	0.8274	0.0731	0.7048	M4-M5 FP16
6	0.0689	0.6987	0.0421	0.7098	INT8	19	0.1081	0.8140	0.0616	0.7366	M5 FP16
7	0.0702	0.7861	0.0418	0.7023	INT8	20	0.1107	0.6298	0.0622	0.7653	M5 FP16
8	0.1005	0.6774	0.0621	0.6770	INT8	21	0.1074	0.6207	0.0582	0.7919	M5 FP16
9	0.0703	0.7109	0.0440	0.6697	INT8	22	0.0386	0.2541	0.0199	0.8203	INT8
10	0.0963	1.7752	0.0609	0.6673	INT8	23	0.0446	0.4270	0.0190	0.8176	INT8
11	0.0838	0.7812	0.0542	0.6414	INT8	Head	0.1957	0.7799	0.1174	0.1871	固定 FP32
12	0.0554	1.0831	0.0401	0.6366	INT8						

L_i 表示同输入局部 CPU-MIGRAPHX MAE, C_i 表示累计链 MAE。它们不是纯量化误差或任务损失敏感性。粗体为 M1-M4 依次使用的峰值 block; M5 进一步保护连续区域中的 15、16 和 19-21。主机暂存诊断中的计时不属于性能证据。

B. 严格跨提供者 Logit 诊断

表 V 永久保留同一冻结 artifact 在单幅真实输入上的 CPU 与 MIGRAPHX FP32 输出 logits 诊断。预定义严格跨提供者诊断容差为 MAE 不超过 10^{-3} 、最大绝对误差不超过 5×10^{-2} 、像素类别一致率不低于 99.9%。这些阈值用于诊断严格跨提供者可互换性，与 90 幅影像的应用级分割门槛相互独立。

该诊断失败在证据记录中永久保留，它禁止严格 logits 等价或跨提供者校准可互换的 claim。论文的应用部署准入则依据冻结 90 幅影像的分割指标与运行验收，因此该诊断不作为应用级阻塞项。

C. 任务效用

表 VI 给出冻结的 90 样本结果。同拓扑 FP32 完全复现参考任务指标；Full FP16 的 mIoU 仅下降 0.0131 pp。M0-M5 全部在 3 个独立进程中通过预注册的应用级任务门槛，且三轮指标跨度均为 0。该重复性只说明固定样本与冻结运行协议下的确定性，不能替代跨场景统计置信区间。M4 具有最高的混合精度 mIoU 和 Water IoU；M5 精度略低于 M4，但仍接近 FP32，并在后续性能与部署分析中体现容量价值。

M0 到 M1 的提升与 block 0 较大的后端差异一致：只保护这一段便恢复了大部分任务指标损失。后续 FP16 替换并没有形成单调的指标序列；残差路径会衰减或放大扰动，解码器又会读取多个深度的特征。因此，逐段后端差异只能用于构造待验证配置，不能被解释为单层任务因果效应，也不能据此机械排序。

图 3 为全局指标提供空间层面的补充。在稀疏水体场景中，三条执行路径都漏掉了大部分零散小水体；在中等和大范围水体场景中，误检与漏检主要集中于狭窄岸线和破碎边界，而 Full FP16 与 M5 对主体水体几何形状的保持接近同拓扑 FP32。该图用于展示误差形态，不构成新的精度估计。

D. 逻辑容量与压缩效果

表 VII 比较可执行模型与编译缓存容量。分段 FP32 分母由 25 个 ONNX 文件和 25 个 MXR 缓存组成，合计 2,691,090,617 字节 (2566.424 MiB)；M0-M5 采用相同的 25 段统计方法。Full FP16 则统计其正式部署使用的单体 ONNX 与一个配对 MXR 缓存。对于候选 i ，节省容量定义为 $S_{FP32} - S_i$ ，缩减比例为 $(1 - S_i/S_{FP32}) \times 100\%$ ，压缩倍数为 S_{FP32}/S_i 。Full FP16 容量为 1284.756 MiB，相对 FP32 缩减 49.940%，压缩倍数为 1.998 $\times$ 。M0 最小，为 763.951 MiB 和 3.359 $\times$ ；M5 因保留更多 FP16 高差异 block，容量为 981.759 MiB，压缩倍数为 2.614 $\times$ 。这说明浮点保护以一定容量为代价换取任务精度，但所有混合候选相对分段 FP32 仍至少缩减 61% 以上。

上述数值描述一个可执行配置的 ONNX+MXR 逻辑载荷，不包含容器镜像、Python 与运行时依赖、文件系统实际占用，也不计入不同候选之间的硬链接共享。Full FP16 为单体拓扑，而 FP32 与 M0-M5 为分段拓扑，因此该行只用于存储容量比较，不用于同拓扑执行性能比较。这些数值也不能与后文的完整部署 bundle

表 V
一幅冻结真实输入上的严格 CPU-MIGRAPHX LOGIT 诊断

Artifact	MAE	最大绝对误差	类别一致率	预定义容差	状态
Full FP16	0.003715	0.013458	100.0000%	$10^{-3}/5 \times 10^{-2}/99.9\%$	failed (MAE)
M0	0.110935	0.609328	99.9960%	同上	failed
M1	0.126587	0.473313	100.0000%	同上	failed
M2	0.094231	0.407406	100.0000%	同上	failed
M3	0.104744	0.387089	100.0000%	同上	failed
M4	0.108455	0.393831	100.0000%	同上	failed
M5	0.092546	0.388980	100.0000%	同上	failed

表 VI
固定 90 样本上的任务指标

变体	mIoU	Water IoU	Boundary Water IoU	Pixel Acc.	一致率	骨干 block (FP32/FP16/INT8)	状态
FP32	0.860587	0.757838	0.362581	0.967110	100.0000%	24/0/0	参考
Full FP16	0.860456	0.757588	0.361931	0.967094	99.9812%	0/24/0	通过
M0	0.859288	0.755400	0.361058	0.966947	99.7071%	0/0/24	通过
M1	0.860324	0.757386	0.362813	0.967077	99.8789%	0/1/23	通过
M2	0.860044	0.756883	0.362193	0.967050	99.8731%	0/2/22	通过
M3	0.860228	0.757201	0.362100	0.967065	99.8767%	0/3/21	通过
M4	0.860371	0.757470	0.362530	0.967085	99.8753%	0/4/20	通过
M5	0.860272	0.757295	0.362517	0.967029	99.8781%	0/9/15	通过

FP32 与 M0-M5 的 UPerNet head 保持 FP32。Full FP16 遵循正式部署的单体兼容图：内部 FP16 参数/激活、FP32 岛和 FP32 外部 I/O。所有行均聚合同一 90 幅影像与 3,927,398 个有效像素。

容量直接混用。

图 4 用两个面板区分不同范围的权衡。左侧仅比较同为 25 段拓扑的 FP32 与 M0-M5；右侧单独给出最终部署包的 same-CLI 结果。这样既能展示 INT8 占比比较高的候选更紧凑，也不会把单体 Full FP16 与 25 段配置混成精度专属的硬件加速比。

E. 同拓扑性能

表 VIII 只比较采用相同 25 段常驻会话拓扑的 FP32 与 M0-M5。M1-M4 尽管含有 INT8 block，实际均慢于 FP32。M5 与 FP32 近似持平：端到端 logits median 分别为 22.080 ms 和 22.209 ms，差约 0.58%。由于差值很小，且 M5 的尾延迟并未优于 FP32，本文不将其表述为正式 INT8 加速。M0 原始 model-only 轮间 CV 为 6.47%，因此保持 unstable；后续确认实验只作为追加观测，不能覆盖这一冻结事实。

因此，Pareto 分析保留多个具有不同作用的候选，而不是强行选择一个“最佳 INT8 模型”：M0 是最大压

缩候选，但原始时序状态保持不稳定；M1 是恢复 M0 大部分任务退化且满足时序稳定门槛的首个紧凑稳定配置；M4 是精度取向混合点；M5 是分段时延取向点和最终存储取向部署备选。Full FP16 继续作为生产式部署速度参照，它与 M5 的正式配对结果单独列于表 IX。

F. 内核与放置证据

所有通过准入的候选均满足 25 个段 MIGraphX 事件大于 0、CPU 提供者事件为 0。Kernel 分析覆盖 33 个去重 trace，其中包含 24 个 INT8 身份和 9 个 FP16 身份，并展开为 144 个“候选-block”映射。在本文冻结 artifact 与 trace 协议中，所有保留的 INT8 block 均观察到 I8II GEMM 路径，所有 FP16 block 均观察到 HBH 路径。

这比检查 ONNX 数据类型更接近实际硬件证据，但仍只是 block 级 GEMM 路径证据。FP32 head、LayerNorm 浮点岛、Q/DQ、Cast、布局转换和数据复制仍属于完整流水线；trace 还包含会话与 MXR 加

表 VII
不同混合精度相对同拓扑 FP32 的 ONNX+MXR 逻辑容量与压缩效果

方案	Backbone 精度映射	ONNX (MiB)	MXR (MiB)	合计 (MiB)	相对 FP32 节省 (MiB)	缩减比例	压缩倍数
FP32	24 个 FP32 块	1218.134	1348.290	2566.424	0.000	0.000%	1.000×
Full FP16	单体 FP16	609.370	675.386	1284.756	1281.668	49.940%	1.998×
M0	0 个 FP16 + 24 个 INT8 块	350.990	412.960	763.951	1802.473	70.233%	3.359×
M1	1 个 FP16 + 23 个 INT8 块	364.016	425.362	789.378	1777.046	69.242%	3.251×
M2	2 个 FP16 + 22 个 INT8 块	375.936	437.417	813.353	1753.071	68.308%	3.155×
M3	3 个 FP16 + 21 个 INT8 块	387.856	449.666	837.522	1728.903	67.366%	3.064×
M4	4 个 FP16 + 20 个 INT8 块	399.776	461.913	861.689	1704.735	66.425%	2.978×
M5	9 个 FP16 + 15 个 INT8 块	459.375	522.384	981.759	1584.665	61.746%	2.614×

表 VIII
25 段配置的同拓扑性能 (BATCH 1, 30 次预热, 3×100 次)

变体	Model-only median (ms)	端到端 logits median (ms)	速度因子 $T_{\text{FP32}}/T_{\text{variant}}$	增量显存 (GiB)	CV 状态	解释
FP32	21.349	22.209	1.000×	19.230	通过	同协议分母
M0	24.136	24.823	0.895×	17.200–17.400	不稳定	最大压缩
M1	23.550	24.274	0.915×	17.200–17.400	通过	紧凑稳定
M2	23.411	24.179	0.919×	17.200–17.400	通过	慢于 FP32
M3	23.118	23.925	0.928×	17.200–17.400	通过	慢于 FP32
M4	22.829	23.540	0.944×	17.200–17.400	通过	精度优先
M5	21.339	22.080	1.006×	17.200–17.400	通过	时延持平; 不作加速 claim

注: 速度因子大于 1 表示中位时延低于分段 FP32, 小于 1 表示更高; 只在相同 25 段拓扑内计算。M5 的 1.006× 按时延持平处理, 不构成正式加速 claim。Full FP16 的生产式 same-CLI 结果单独列于表 IX。

载以及输入输出传输。因此, 该结果不证明全图所有算子均为整数, 也不能单独证明模型级加速。

G. 部署容量与 same-CLI 对比

M5 部署包包含 74 个 payload 文件, 总计 1,032,911,027 字节; Full FP16 包含 19 个 payload 文件, 总计 1,349,558,844 字节。M5 完整部署载荷减少 316,647,817 字节, 即 23.463%。该完整 bundle 口径包含可执行产物、manifest、工具和固定验证数据, 既不同于仅统计 ONNX 文件的压缩率, 也不同于表 VII 中的 ONNX+MXR 逻辑容量。

最终配对实验使用相同公共 CLI、固定输入、runner 实现和 3×100 协议。表 IX 表明, 尽管 M5 更小并含有已验证的 INT8 GEMM, 它仍显著慢于 Full FP16。这是最终部署选择的决定性证据。

H. 运行验收

两个不可变部署包均通过完整静态校验, 包括 manifest 与 payload 哈希、运行时指纹、输入输出契

表 IX
最终部署包的生产式 SAME-CLI 比较

部署包	Median (ms)	P95 (ms)	P99 (ms)	吞吐量 (sample/s)
M5	26.309	28.518	30.744	37.641
Full FP16	15.151	15.552	17.594	65.900

M5/FP16 median 时延比为 1.7364, M5 慢 73.642%。M5 和 FP16 的轮间 median CV 分别为 0.413% 和 0.086%。该比较同时改变图拓扑与精度映射, 只能用于最终部署决策, 不能解释为纯 INT8/FP16 算术峰值排名。

约和固定向量预测。二者均通过 5 次冷启动和 3 次主动终止后重载。M5 和 FP16 的 session 加载中位时间分别为 8.883 s 和 10.086 s, runner 初始化总时间分别为 10.281 s 和 11.570 s; 这些属于启动指标, 不作为稳态吞吐证据。

两个部署包均在 K100-2 和 K100-3 通过带外层启动环境证明的正式冒烟测试。60 分钟连续运行中, M5 完成 123,106 次推理, FP16 完成 193,634 次推理; 每个测试均保存 720 条遥测, 且崩溃、推理错误、非有




图 3. 三个固定测试场景上的洪水水体定性检测结果。样本在所有含有效水体像素的真值掩膜中，按有效像素水体占比的第 25、第 75 和第 95 百分位独立确定，选择过程不使用模型精度。青色表示真值水体；预测行在 RED-GREEN-BLUE 合成影像上以绿色表示正确检出、蓝色表示误检、红色表示漏检。该图仅作定性展示，不能替代 VI 的 90 幅影像量化指标。

限输出和固定样本预测漂移全部为 0。M5 温度范围为 41–67°C、功耗范围为 108–217 W；FP16 温度范围为 43–59°C、功耗范围为 109–202 W。此前两次 K100-3 无效环境尝试和一次外层证明工具失败均通过排除账本保留，均不计入正式验收，且没有一次到达成功模型推理。

VI. 讨论

A. 后端差异诊断的解释

逐段结果表明，CPU-MIGraphX 差异并不随深度单调累积。segment 0 同时包含输入前端与第一个 Transformer block，较大的局部差异会进入后续残差流；block 14–21 则形成第二个高差异区域。残差相加、归一化、注意力混合和 MLP 投影都可能改变扰动的方向与幅度，任务头还会消费多个深度的特征。因此， L_i 或 C_i 不能直接等同于任务损失敏感性。M0、M1、M4 和 M5 分别是固定的最大压缩、紧凑稳定、精度取向和分段时延取向消融点；最终判断仍来自完整 90 样本任务评估。

B. 为什么已验证的 INT8 内核不保证端到端加速

M5 已经满足逐 block I8II 证据，但在 same-CLI 下仍输给单会话 Full FP16。该现象与多会话调度、段

边界、Q/DQ、FP32 段间接口、Cast、布局变换、FP32 head 和剩余浮点算子的组合影响一致。当前实验没有单独计时这些部分，因此不把时延差距中的任何数值比例归因于某一来源。“存在 INT8 内核”与“应用系统变快”仍是两个必须分别取证的主张。

C. 部署含义

所有部署候选均通过应用级分割门槛，并在三轮 90 样本评估中保持稳定。但是，历史 CPU/MIGraphX 严格 logits 诊断对 INT8 与混合精度 artifact 仍保持 failed，本文不隐藏或改写该结果。因此，证据支持的是：在冻结数据与指标协议下，分割任务得到保持，artifact 可在目标 K100 软件栈上可靠执行；证据不支持逐位等价或严格跨提供者 logits 复现。对于依赖概率校准、阈值敏感决策或跨后端精确复现的应用，仍需额外验证。

运行层面，M5 与 Full FP16 均通过静态完整性、冷启动、恢复、双节点冒烟和 60 分钟稳定性验收，说明二者都具备操作性部署资格。容量与性能则给出不同取向：M5 完整部署载荷少 23.463%，但 same-CLI 时延高 73.642%。因此，“能够部署”与“应当作为默认方案”必须分开表述。

D. 有效性威胁

内部有效性：校准使用官方训练集 64 幅影像，但没有为配置选择保留独立 split。M0–M5 的构造使用了一幅公开测试影像，随后又在包含该影像的固定 90 样本上评估，因此存在配置选择偏差；该实验是部署案例验证，而不是无偏的配置泛化估计。

构念有效性：提供者事件为 0 只能说明 profile 中未观察到 CPU 执行；I8II/HBH 只证明所跟踪 GEMM 路径，不代表整图所有算子均采用相应精度。ONNX+MXR 逻辑容量与完整 bundle 载荷是不同构念，严格 logits 等价与任务指标保持也是不同目标。

外部有效性：结论针对一个 Prithvi-EO-2.0 分割 checkpoint、Sen1Floods11 固定测试集、batch 1、两台 K100 节点以及当前 DTK/MIGraphX/ONNX Runtime 组合。25 段图是兼容性策略，不代表其他模型、任务、batch、节点或软件版本的最优实现。

结论有效性：三个新进程只刻画运行重复性，不提供 scene-level 置信区间或统计显著性检验；M4 与 M5 的小差异仅为描述性结果。功耗与温度是运行观测而非受控能效实验；M5 相对 25 段 FP32 约 0.58% 的中位




图 4. 任务精度、逻辑容量与系统时延的分范围权衡。左：同拓扑 25 段 FP32 与 M0-M5；右：最终 M5 与单体 Full FP16 部署包的 same-CLI 结果。两个面板采用不同执行范围，不能合并推导精度专属加速比。

时延差值只表述为持平。当前证据足以支持冻结协议下的部署决策，但不足以支持通用混合精度优化 claim。

E. 最终部署推荐

对于本文评估的 checkpoint 与 K100 软件栈，Full FP16 凭借近 FP32 任务精度、15.151 ms same-CLI 中位时延和较简单的单体执行路径，作为速度优先的默认部署方案。M5 通过全部任务与运行验收，并满足完整部署载荷至少减少 20% 的条件，因此作为存储受限场景的可部署备选；它不取代 Full FP16，也不构成 INT8 加速结论。M4 保留为精度取向混合精度消融点，M1 为紧凑稳定/首次恢复点，M0 记录最大压缩但时序不稳定。该推荐是本部案例的工程选择，不是可跨硬件迁移的通用混合精度策略。

VII. 结论

本文给出了 Prithvi-EO-2.0-300M 与 UPerNet 在 K100 上的完整可审计部署案例。同拓扑 25 段 FP32 分母避免了跨拓扑性能误读；提供者 profile 与 kernel trace 分别验证执行放置和目标 GEMM 路径；不可变部署包补齐了双节点、恢复和 60 分钟运行证据。对于所评估的 checkpoint 和软件栈，M5 保持接近 FP32 的任务指标，完整部署载荷减少 23.463%，并与 25 段 FP32 时延持平，但在 same-CLI 下比单体 Full FP16 慢 73.642%，且没有建立严格跨提供者 logits 等价或正式 INT8 加速。因此，Full FP16 是速度取向主部署，M5

是更小的存储取向备选；这些结论属于冻结协议下的部署决策，不是通用精度策略或普遍 block 敏感性规律。

参考文献

- [1] D. Szwarcman, S. Roy, P. Fraccaro *et al.*, “Prithvi-EO-2.0: A versatile multitemporal foundation model for earth observation applications,” *IEEE Transactions on Geoscience and Remote Sensing*, vol. 64, pp. 1–20, 2026.
- [2] Y. Cong, S. Khanna, C. Meng, P. Liu, E. Rozi, Y. He, M. Burke, D. Lobell, and S. Ermon, “SatMAE: Pre-training transformers for temporal and multi-spectral satellite imagery,” in *Advances in Neural Information Processing Systems*, vol. 35, 2022.
- [3] Z. Yuan, C. Xue, Y. Chen, Q. Wu, and G. Sun, “PTQ4ViT: Post-training quantization for vision transformers with twin uniform quantization,” in *European Conference on Computer Vision*, 2022.
- [4] Y. Lin, T. Zhang, P. Sun, Z. Li, and S. Zhou, “FQ-ViT: Post-training quantization for fully quantized vision transformer,” in *International Joint Conference on Artificial Intelligence*, 2022, pp. 1173–1179.
- [5] Z. Li, J. Xiao, L. Yang, and Q. Gu, “RepQ-ViT: Scale reparameterization for post-training quantization of vision transformers,” in *IEEE/CVF International Conference on Computer Vision*, 2023, pp. 17 227–17 236.
- [6] Z. Yao, Z. Dong, Z. Zheng, A. Gholami, J. Yu, E. Tan, L. Wang, Q. Huang, Y. Wang, M. Mahoney, and K. Keutzer, “HAWQ-V3: Dyadic neural network quantization,” in *Proceedings of the 38th International Conference on Machine Learning*, ser. Proceedings of Machine Learning Research, vol. 139. PMLR, 2021, pp. 11 875–11 886. [Online]. Available: <https://proceedings.mlr.press/v139/yao21a.html>
- [7] T. Xiao, Y. Liu, B. Zhou, Y. Jiang, and J. Sun, “Unified perceptual parsing for scene understanding,” in *European Conference on Computer Vision*, 2018, pp. 418–434.

- [8] A. Dosovitskiy *et al.*, “An image is worth 16×16 words: Transformers for image recognition at scale,” in *International Conference on Learning Representations*, 2021. [Online]. Available: <https://openreview.net/forum?id=YicbFdNTTy>
- [9] C. J. Reed, R. Gupta, S. Li, S. Brockman, C. Funk, B. Clipp, K. Keutzer, S. Candido, M. Uyttendaele, and T. Darrell, “Scale-MAE: A scale-aware masked autoencoder for multiscale geospatial representation learning,” in *IEEE/CVF International Conference on Computer Vision*, 2023, pp. 4088–4099. [Online]. Available: https://openaccess.thecvf.com/content/ICCV2023/html/Reed_Scale-MAE_A_Scale-Aware_Masked_Autoencoder_for_Multiscale_Geospatial_Representation_Learning_ICCV_2023_paper.html
- [10] A. Fuller, K. Millard, and J. R. Green, “CROMA: Remote sensing representations with contrastive radar-optical masked autoencoders,” in *Advances in Neural Information Processing Systems*, vol. 36, 2023, pp. 5506–5538.
- [11] X. Sun, P. Wang, W. Lu, Z. Zhu, X. Lu, Q. He, J. Li, X. Rong, Z. Yang, H. Chang, Q. He, G. Yang, R.-P. Wang, J. Lu, and K. Fu, “RingMo: A remote sensing foundation model with masked image modeling,” *IEEE Transactions on Geoscience and Remote Sensing*, vol. 61, pp. 1–22, 2023.
- [12] M. Mendieta, B. Han, X. Shi, Y. Zhu, and C. Chen, “Towards geospatial foundation models via continual pretraining,” in *IEEE/CVF International Conference on Computer Vision*, 2023, pp. 16 806–16 816. [Online]. Available: https://openaccess.thecvf.com/content/ICCV2023/html/Mendieta_Towards_Geospatial_Foundation_Models_via_Continual_Pretraining_ICCV_2023_paper.html
- [13] X. Guo, J. Lao, B. Dang, Y. Zhang, L. Yu, L. Ru, L. Zhong, Z. Huang, K. Wu, D. Hu, H. He, J. Wang, J. Chen, M. Yang, Y. Zhang, and Y. Li, “SkySense: A multi-modal remote sensing foundation model towards universal interpretation for earth observation imagery,” in *IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2024, pp. 27 672–27 683. [Online]. Available: https://openaccess.thecvf.com/content/CVPR2024/html/Guo_SkySense_A_Multi-Modal_Remote_Sensing_Foundation_Model_Towards_Universal_Interpretation_CVPR_2024_paper.html
- [14] Z. Xiong, Y. Wang, F. Zhang, A. J. Stewart, J. Hanna, D. Borth, I. Papoutsis, B. L. Saux, G. Camps-Valls, and X. X. Zhu, “Neural plasticity-inspired multimodal foundation model for earth observation,” *arXiv preprint arXiv:2403.15356*, 2024.
- [15] B. Jacob, S. Kligys, B. Chen, M. Zhu, M. Tang, A. Howard, H. Adam, and D. Kalenichenko, “Quantization and training of neural networks for efficient integer-arithmetic-only inference,” in *IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2018, pp. 2704–2713.
- [16] Z. Liu, Y. Wang, K. Han, W. Zhang, S. Ma, and W. Gao, “Post-training quantization for vision transformer,” in *Advances in Neural Information Processing Systems*, vol. 34, 2021, pp. 28 092–28 103. [Online]. Available: <https://proceedings.neurips.cc/paper/2021/hash/ec8956637a99787bd197eacd77acce5e-Abstract.html>
- [17] K. Wang, Z. Liu, Y. Lin, J. Lin, and S. Han, “HAQ: Hardware-aware automated quantization with mixed precision,” in *IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2019, pp. 8612–8620. [Online]. Available: https://openaccess.thecvf.com/content_CVPR_2019/html/Wang_HAQ_Hardware-Aware_Automated_Quantization_With_Mixed_Precision_CVPR_2019_paper.html
- [18] N. Ranjan and A. Savakis, “Mix-QViT: Mixed-precision vision transformer quantization driven by layer importance and quantization sensitivity,” in *IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops*, 2026, pp. 3599–3609. [Online]. Available: https://openaccess.thecvf.com/content/CVPR2026W/ECV/html/Ranjan_Mix-QViT_Mixed-Precision_Vision_Transformer_Quantization_Driven_by_Layer_Importance_and_CVPRW_2026_paper.html
- [19] Microsoft, “ONNX Runtime MIGraphX Execution Provider,” Online documentation, 2026, accessed: 2026-08-19. [Online]. Available: <https://onnxruntime.ai/docs/execution-providers/MIGraphX-ExecutionProvider.html>
- [20] Advanced Micro Devices, Inc., “MIGraphX documentation: Deep-learning compilation and ONNX Runtime execution provider,” Online documentation, 2026, accessed: 2026-08-19. [Online]. Available: <https://rocm.docs.amd.com/projects/AMDMMIGraphX/en/latest/>
- [21] V. J. Reddi, C. Cheng, D. Kanter, P. Mattson *et al.*, “MLPerf inference benchmark,” in *ACM/IEEE 47th Annual International Symposium on Computer Architecture*, 2020, pp. 446–459.
- [22] T. Shinde, “Model compression meets resolution scaling for efficient remote sensing classification,” in *IEEE/CVF Winter Conference on Applications of Computer Vision Workshops*, 2025, pp. 1200–1209.
- [23] C. Butsko, K. V. Tricht, G. Tseng, G. Milli, D. Rolnick, R. Cartuyvels, I. B. Reshef, Z. Szantoi, and H. Kerner, “Deploying geospatial foundation models in the real world: Lessons from WorldCereal,” *arXiv preprint arXiv:2508.00858*, 2025.
- [24] G. Giuffrida, L. Fanucci, G. Meoni, M. Batic, L. Buckley, A. Dunne, C. V. Dijk, M. Esposito, J. Hefele, N. Vercruyssen, G. Furano, M. Pastena, and J. Aschbacher, “The PhiSat-1 mission: The first on-board deep neural network demonstrator for satellite earth observation,” *IEEE Transactions on Geoscience and Remote Sensing*, vol. 60, pp. 1–14, 2022.
- [25] H. Sang, L. Zhang, T. Chen, W. Guo, and Z. Zhang, “Onboard deployment of remote sensing foundation models: A comprehensive review of architecture, optimization, and hardware,” *Remote Sensing*, vol. 18, no. 2, p. 298, 2026.
- [26] D. Bonafilia, B. Tellman, T. Anderson, and E. Issenberg, “Sen1Floods11: A georeferenced dataset to train and test deep learning flood algorithms for sentinel-1,” in *IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops*, 2020.